

STATISTIQUES À DEUX VARIABLES - NIVEAU PREMIÈRE & TERMINALE

1. Série à deux variables

Définition

Une **série statistique à deux variables** associe à chaque individu deux caractères quantitatifs notés x et y .

Exemple :

On étudie 10 élèves :

- x = nombre d'heures de révision
- y = note obtenue à l'examen

Élève	1	2	3	4	5
Heures x	2	4	6	8	10
Note y	8	12	14	17	19

2. Nuage de points


Définition

Le **nuage de points** est la représentation graphique des couples $(x_i; y_i)$ dans un repère orthogonal.

Construction :

- En abscisse : les valeurs de x
- En ordonnée : les valeurs de y
- Chaque individu devient un point

Exemple visuel :



Point moyen G :

$$G(\bar{x}; \bar{y}) \quad \text{avec} \quad \bar{x} = \frac{1}{n} \sum_{i=1}^n x_i \quad \text{et} \quad \bar{y} = \frac{1}{n} \sum_{i=1}^n y_i$$

Le point moyen est le **centre de gravité** du nuage.

3. Ajustement

Pourquoi ajuster ?

*L'ajustement permet de **modéliser** la relation entre x et y par une fonction, afin de **prévoir** des valeurs (interpolation ou extrapolation).*

Types d'ajustement

Type	Équation	Quand l'utiliser ?
Affine	$y = ax + b$	Nuage allongé, tendance linéaire
Parabolique	$y = ax^2 + bx + c$	Nuage en forme de U ou $\cap$
Polynôme degré 3	$y = ax^3 + bx^2 + cx + d$	Nuage avec un point d'inflexion
Exponentiel	$y = a \times e^{bx}$ ou $y = a \times b^x$	Croissance ou décroissance rapide
Logarithmique	$y = a \times \ln(x) + b$	Croissance qui ralentit

4. Ajustement affine (le plus fréquent)

Méthode de Mayer (ou méthode des points moyens)

Principe : On partage le nuage en deux groupes de même effectif, on calcule les points moyens G_1 et G_2 , puis on trace la droite (G_1G_2) .

Étapes :

1. Ranger les points par ordre croissant des x
2. Partager en deux groupes égaux
3. Calculer $G_1(\overline{x_1}; \overline{y_1})$ et $G_2(\overline{x_2}; \overline{y_2})$
4. Déterminer $a = \frac{\overline{y_2} - \overline{y_1}}{\overline{x_2} - \overline{x_1}}$ et b par substitution

Méthode des moindres carrés (Terminale)

Principe : On minimise la somme des carrés des écarts verticaux entre les points et la droite.

Formules :

$$a = \frac{\text{cov}(x, y)}{V(x)} \quad \text{et} \quad b = \overline{y} - a\overline{x}$$

Avec :

- **Covariance :** $\text{cov}(x, y) = \frac{1}{n} \sum_{i=1}^n (x_i - \overline{x})(y_i - \overline{y}) = \frac{1}{n} \sum_{i=1}^n x_i y_i - \overline{x} \overline{y}$

- **Variance de x :** $V(x) = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2 = \frac{1}{n} \sum_{i=1}^n x_i^2 - \bar{x}^2$

Propriété importante : La droite des moindres carrés passe par le point moyen $G(\bar{x}; \bar{y})$.

Démonstration de la formule (à connaître pour l'oral)

Objectif : Minimiser $S(a, b) = \sum_{i=1}^n (y_i - (ax_i + b))^2$

Étape 1 : Dérivée partielle par rapport à b

$$\frac{\partial S}{\partial b} = -2 \sum_{i=1}^n (y_i - ax_i - b) = 0$$

$$\sum_{i=1}^n y_i - a \sum_{i=1}^n x_i - nb = 0$$

$$n\bar{y} - an\bar{x} - nb = 0 \quad \Rightarrow \quad b = \bar{y} - a\bar{x}$$

Étape 2 : Dérivée partielle par rapport à a

$$\frac{\partial S}{\partial a} = -2 \sum_{i=1}^n x_i (y_i - ax_i - b) = 0$$

$$\sum_{i=1}^n x_i y_i - a \sum_{i=1}^n x_i^2 - b \sum_{i=1}^n x_i = 0$$

Étape 3 : On remplace b par $\bar{y} - a\bar{x}$

$$\sum x_i y_i - a \sum x_i^2 - (\bar{y} - a\bar{x}) \sum x_i = 0$$

$$\sum x_i y_i - a \sum x_i^2 - \bar{y} \sum x_i + a\bar{x} \sum x_i = 0$$

$$\sum x_i y_i - \bar{y} \sum x_i - a \left(\sum x_i^2 - \bar{x} \sum x_i \right) = 0$$

Or $\sum x_i = n\bar{x}$ et $\sum x_i^2 - \bar{x} \sum x_i = \sum x_i^2 - n\bar{x}^2 = nV(x)$

Et $\sum x_i y_i - \bar{y} \sum x_i = \sum x_i y_i - n\bar{x}\bar{y} = n \operatorname{cov}(x, y)$

Donc :

$$n \operatorname{cov}(x, y) - a \times nV(x) = 0 \quad \Rightarrow \quad a = \frac{\operatorname{cov}(x, y)}{V(x)}$$

CQFD

5. Coefficient de détermination R^2

Définition

Le coefficient de détermination R^2 mesure la **qualité de l'ajustement**. Il est compris entre 0 et 1.

$$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2}$$

Où :

- y_i = valeur réelle
- $\hat{y}_i$ = valeur prédite par le modèle
- $\bar{y}$ = moyenne des y

Interprétation

R^2	Qualité de l'ajustement
Proche de 1	Excellent : le modèle explique bien les données
$\geq 0,9$	Très bon
0,7 à 0,9	Bon
0,5 à 0,7	Moyen
$< 0,5$	Mauvaise : le modèle n'est pas adapté

Exemple : $R^2 = 0,95$ signifie que 95% de la variation de y est expliquée par le modèle.

Dans le cas affine : $R^2 = r^2$

Pour un ajustement affine, R^2 est égal au **carré du coefficient de corrélation linéaire r** :

$$r = \frac{\text{cov}(x, y)}{\sigma_x \sigma_y} \quad \text{et} \quad R^2 = r^2$$

6. Choix du modèle : comment décider ?

Méthode visuelle

On observe la forme du nuage et on choisit le modèle dont la courbe "épouse" le mieux les points.

Forme du nuage	Modèle suggéré
Points alignés	Affine $y = ax + b$
Parabole (U ou $\cap$)	Parabolique $y = ax^2 + bx + c$
Croissance qui ralentit	Logarithmique $y = a \ln(x) + b$
Croissance qui accélère	Exponentiel $y = ae^{bx}$
Forme de S ou sigmoïde	Polynôme degré 3

Méthode du R^2 le plus élevé

On teste plusieurs modèles et on garde celui qui a le R^2 le plus proche de 1.

Exemple :

- Modèle affine : $R^2 = 0,82$
- Modèle exponentiel : $R^2 = 0,94 \rightarrow$ on choisit l'exponentiel

7. Interpolation et extrapolation

Définitions

Terme	Définition	Exemple
Interpolation	Prédire une valeur de y pour un x à l'intérieur de l'intervalle des données	x entre 2 et 10 heures de révision
Extrapolation	Prédire une valeur de y pour un x à l'extérieur de l'intervalle des données	$x = 15$ heures de révision

Précautions

L'extrapolation est risquée : on suppose que la tendance observée se prolonge, ce qui n'est pas toujours vrai.

Exemple :

Si on ajuste la croissance d'une population par un exponentiel, l'extrapolation sur 100 ans peut donner des nombres absurdes (ressources limitées).

8. Exemple complet (affine)

Données : Ventes d'un produit en fonction du prix

Prix x (€)	5	10	15	20	25
Ventes y	120	95	75	50	35

Calculs :

- $\bar{x} = 15$
- $\bar{y} = 75$
- $\text{cov}(x, y) = \frac{5 \times 120 + 10 \times 95 + 15 \times 75 + 20 \times 50 + 25 \times 35}{5} - 15 \times 75 = 1375 - 1125 = 250$
- $V(x) = \frac{25 + 100 + 225 + 400 + 625}{5} - 225 = 275 - 225 = 50$
- $a = \frac{250}{50} = -5$
- $b = 75 - (-5) \times 15 = 75 + 75 = 150$

Droite d'ajustement : $y = -5x + 150$

Interprétation : Chaque augmentation de 1€ du prix diminue les ventes de 5 unités.

Interpolation : Pour $x = 12$ €, on prédit $y = -5 \times 12 + 150 = 90$ ventes.

R^2 : À calculer, mais ici la tendance est très linéaire $\rightarrow R^2$ proche de 0,95.

9. Tableau récapitulatif des modèles

Modèle	Équation	Linéarisation possible ?
Affine	$y = ax + b$	Déjà linéaire
Parabolique	$y = ax^2 + bx + c$	Poser $X = x^2$
Polynôme degré 3	$y = ax^3 + bx^2 + cx + d$	Poser $X_1 = x^3, X_2 = x^2$
Exponentiel	$y = ae^{bx}$	$\ln(y) = \ln(a) + bx$
Logarithmique	$y = a \ln(x) + b$	Poser $X = \ln(x)$